



Pontificia Universidad
JAVERIANA
Bogotá

Clasificación de estado de presión de llantas de vehículos a partir de imágenes

Juan Nicolás Soto Rios
Frank M. Córdoba O.
Katherine Xiomar González Santacruz

Agenda

1. Contextualización
2. Estado del arte
3. Metodología
4. Resultados
5. Conclusiones
6. Repositorio Github

- 1. Contextualización**
2. Estado del arte
3. Metodología
4. Resultados
5. Conclusiones
6. Repositorio Github

- De acuerdo a la ANSV en Colombia las fallas de las llantas son la segunda causa que más provoca accidentes viales [1].
- Según el **Registro único Nacional de Tránsito**, en 2021 se registraron más de **1970** accidentes asociados a fallas en las llantas, en los cuales **640** personas resultaron heridas, **64** fallecieron y **1271** sufrieron daños materiales [2][3].

- El Ministerio de transporte sugiere que es importante realizar una revisión continua del estado de inflado de las llantas de los vehículos, para mejorar la seguridad a la hora de conducir, la economía del combustible y la vida útil de las llantas [2][3].

- Si las llantas se encuentran un **20%** desinfladas [4]:
 - Se disminuye su vida útil en un **30%**
 - Aumenta el consumo de combustible en un **3%**
 - Riesgo de accidentes
- Falta de conocimiento por parte de algunos conductores [6][7]:

Encuesta en carretera

PMDT (pruebas de defectos mecánicos potenciales) [7]:

8% de los conductores **NO** midieron la presión de las llantas.

90% de los conductores **revisaron** sus llantas al menos una vez al mes.

Pero solo el 40% sabia como realizar **correctamente** las mediciones.

85 % de los encuestados opinaron que se deberían evaluar conocimientos sobre mantenimiento de neumáticos antes de emitir un permiso de conducción.

En las resoluciones número **1349** del 2017 y **1600** de 2005 [8][9] del Ministerio de transporte, donde se habla del examen teórico-práctico para obtener la licencia de conducción:

NO se menciona que sea obligatorio saber cómo medir la presión de aire de las llantas para poder aprobar los exámenes de conducción.

“Todas las precauciones que pueda tener en cuenta previo a un recorrido y la atención que preste cuando detecte alguna **señal de alerta** mientras conduce, le pueden salvar su vida y la de quienes lo acompañan. Las llantas son uno de los elementos más importantes de un vehículo” - **Director de la ANSV** [3].

- Se realizan campañas de concientización para revisión de diferentes aspectos técnicos de los vehículo, como las llantas [3][10].

Todo esto ha promovido la necesidad de implementar sistemas donde se pretende facilitar el reconocimiento del estado de las llantas a través de la tecnología [5] [15] [16]:

- **Inteligencia artificial con reconocimiento de imágenes.**

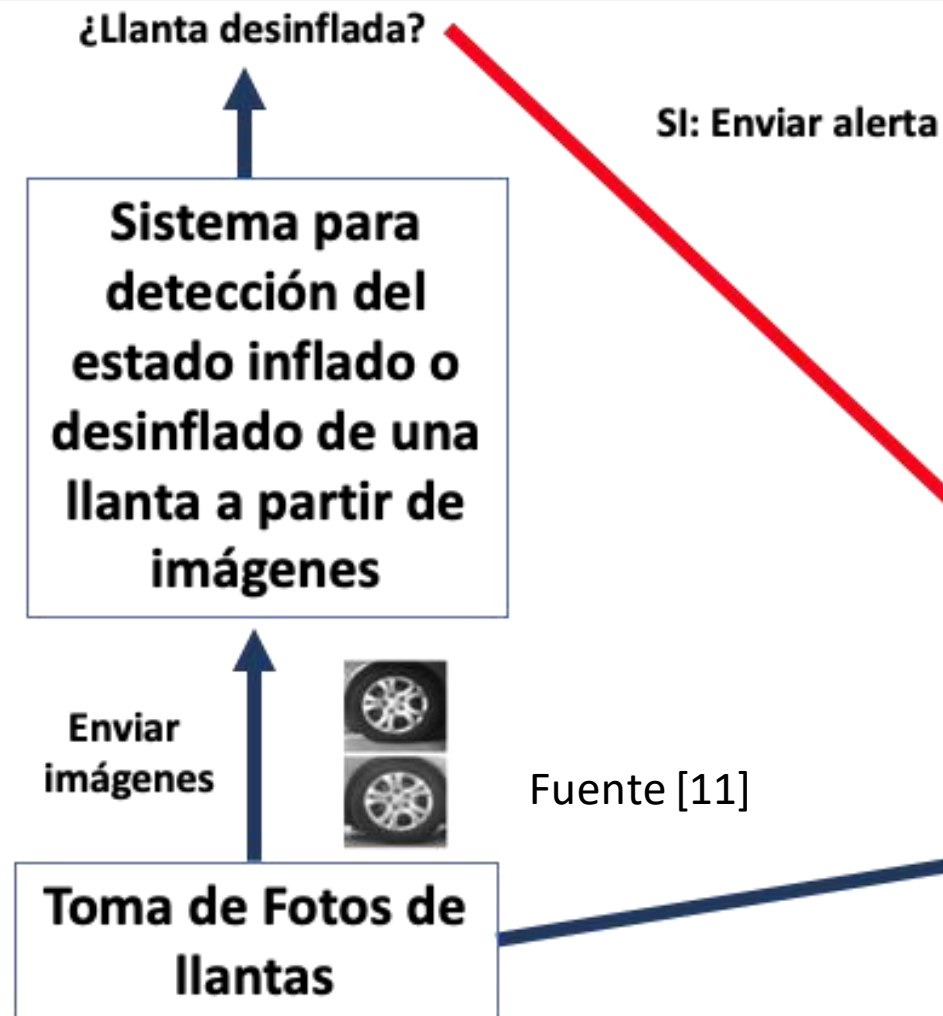
Se implementa un mecanismo de clasificación utilizando algoritmos genéticos para determinar el estado – inflado o desinflado – de una llanta, a partir de imágenes, con el fin de aumentar la seguridad de la conducción, reducir el consumo de combustible, y mejorar la vida útil de las llantas.



Fuente [11]

Propuestas de uso:

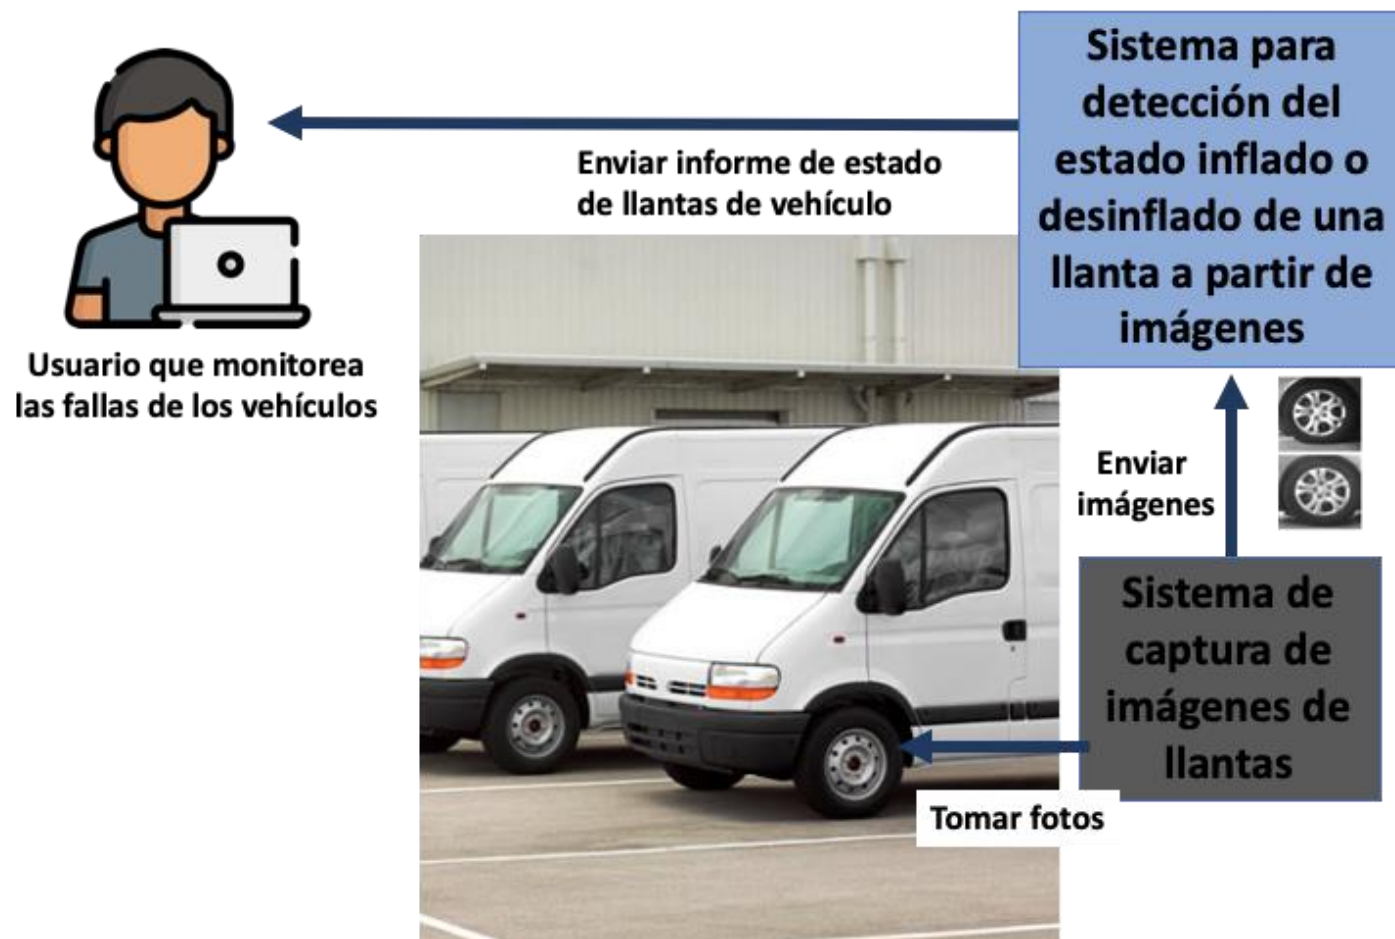
- Alertar a conductores en Peajes



Fuente [12]


Propuestas de uso:

- Para revisión de vehículos en Empresas de Transporte



Propuestas de uso:

- Aplicación Móvil para revisión del estado de las llantas



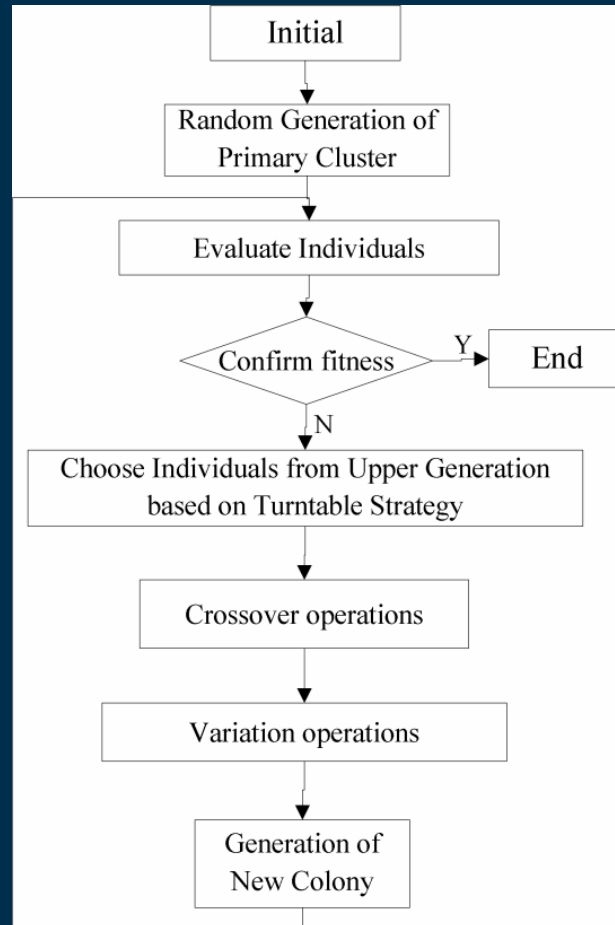
Agenda

1. Contextualización
- 2. Estado del arte**
3. Metodología
4. Resultados
5. Conclusiones
6. Repositorio Github



Classification Techniques of Neural Networks Using Improved Genetic Algorithms

Ming Chen, Zhengwei Yao
School of Computer Science & Engineering
Shanghai University, Shanghai 200072, China
cmyes@shu.edu.cn



(a) SGA Neural Network Classification				
Neural Network Structure	SGA Neural Classification		Neural Network	
	4-8-3		4-4-3	
Colony size	100	250	100	250
Evolution generation quantity	32	15	46	22
Fitness of the best individuals	0.831	0.847	0.824	0.836
Best classification accuracy rate	84%	86%	83%	84%

(b) Improved GA Neural Network Classification				
Neural Network Structure	Improved GA Neural Classification		Neural Network	
	4-8-3		4-4-3	
Colony size	100	250	100	250
Evolution generation quantity	20	9	34	17
Fitness of the best individuals	0.915	0.958	0.908	0.943
Best classification accuracy rate	91%	96%	90%	93%

Puntos Clave

- Tecnología de clasificación basada en un algoritmo genético que practica una red neuronal.
- Datos del Balance Scale Database del Repositorio de aprendizaje automático UCI.
- Algoritmo genético simple (SGA) y mejorado (IGA).
- Precisión máxima del 96%.



Application of SVM Based on Genetic Algorithm in Classification of Cataract Fundus Images

Zhiqiang Qiao¹, Qinyan Zhang¹, Yanyan Dong¹, Ji-Jiang Yang²

1. Automation School, Beijing University of Post and Telecommunications, Beijing, 100876
2. Research Institute of Information Technology, Tsinghua University, Beijing, 100084

Corresponding author: yangjijiang@tsinghua.edu.cn

Puntos Clave

- Clasificación de ojos en normal, con cataratas leve, moderada y grave a partir de imágenes del fondo del ojo.
- Máquina de vectores de soporte (SVM) basada en un algoritmo genético para la ponderación de características.
- La precisión general más alta se da en la de dos categorías (normales-anormales) 95,33%.

processing method	normal	abnormal	overall
non-segment & non-weight	96.14%	76.33%	88.12%
non-segment & weighted	97.43%	85.55%	92.61%
segmented & non-weight	96.22%	91.10%	94.14%
segmented & weighted	96.72%	93.30%	95.33%

processing method	normal	mild	moderate	severe	overall
non-segment & non-weight	95.07%	80.55%	56.15%	25.22%	84.55%
non-segment & weighted	95.36%	81.16%	60.96%	39.13%	85.95%
segmented & non-weight	96.15%	80.70%	41.18%	46.09%	85.06%
segmented & weighted	96.65%	80.70%	67.38%	47.83%	87.52%



Evolutionary Deep Learning: A Genetic Programming Approach to Image Classification

Benjamin Evans, Harith Al-Sahaf, Bing Xue, and Mengjie Zhang

School of Engineering and Computer Science

Victoria University of Wellington, P.O. Box 600

Wellington 6140, New Zealand

{benjamin.evans,harith.al-sahaf,bing.xue,mengjie.zhang}@ecs.vuw.ac.nz

Estado del arte [17]

Puntos Clave

- Clasificación de imágenes.
- Programación genética convolucional (ConvGP): programación genética y aprendizaje profundo con redes neuronales convolucionales (CNN).
- 4 Conjunto de datos, autos, expresiones faciales, caras y peatones.
- ConvGP frecuentemente superó a los métodos básicos de clasificación, sin embargo, no pudo vencer a las CNN.

	Classifier	Training Accuracy (%)		Testing Accuracy (%)		Training Time (minute)		Testing Time (millisecond)	
		$\bar{x} \pm s$	Max	$\bar{x} \pm s$	Max	$\bar{x} \pm s$	Max	$\bar{x} \pm s$	Max
Cars	AdaB	95.27 \pm 1.95	97.20	88.27 \pm 1.09 =	89.40	2.29 \pm 0.12	2.66	0.00 \pm 0.00	0.01
	J48	99.53 \pm 0.09	99.60	85.27 \pm 3.08 =	89.60	0.88 \pm 0.09	1.17	0.01 \pm 0.03	0.19
	k-NN	100.0 \pm 0.00	100.0	94.00 \pm 1.40 =	95.60	3.28 \pm 0.12	3.65	5.65 \pm 0.48	6.46
	NB	93.00 \pm 0.43	93.60	92.20 \pm 0.71 =	92.80	0.79 \pm 0.05	0.94	0.57 \pm 0.02	0.66
	SVM	100.0 \pm 0.00	100.0	95.33 \pm 0.90 =	96.60	0.26 \pm 0.03	0.39	0.02 \pm 0.00	0.02
	ConvNet	100.0 \pm 0.00	100.0	97.88 \pm 0.56 =	99.40	302.30 \pm 12.40	332.12	1.07 \pm 0.11	1.77
	2TGP	93.71 \pm 3.04	97.60	89.45 \pm 3.98 =	97.40	557.72 \pm 137.45	1038.68	0.03 \pm 0.01	0.08
	ConvGP	94.26 \pm 2.11	97.60	90.29 \pm 2.84	95.80	1957.34 \pm 1369.23	7097.00	0.19 \pm 0.19	0.77
JAFFE	AdaB	100.0 \pm 0.00	100.0	84.44 \pm 2.96 =	93.33	0.36 \pm 0.20	1.06	0.00 \pm 0.00	0.02
	J48	100.0 \pm 0.00	100.0	82.22 \pm 2.43 =	90.00	0.07 \pm 0.04	0.29	0.00 \pm 0.00	0.00
	k-NN	100.0 \pm 0.00	100.0	68.89 \pm 5.51 =	86.67	0.07 \pm 0.02	0.17	0.08 \pm 0.01	0.20
	NB	87.78 \pm 1.05	90.00	61.11 \pm 2.75 +	70.00	0.32 \pm 0.06	0.48	0.22 \pm 0.04	0.34
	SVM	100.0 \pm 0.00	100.0	91.11 \pm 2.75 =	100.0	0.06 \pm 0.04	0.26	0.01 \pm 0.00	0.02
	ConvNet	89.93 \pm 13.72	100.0	80.74 \pm 13.4 =	100.0	322.84 \pm 1079.72	7915.27	0.39 \pm 0.04	0.63
	2TGP	96.93 \pm 3.17	100.0	75.22 \pm 11.7 =	96.67	135.62 \pm 63.66	294.90	0.01 \pm 0.02	0.14
	ConvGP	96.19 \pm 3.55	100.0	73.52 \pm 10.5	96.67	354.09 \pm 238.60	1090.92	0.03 \pm 0.02	0.12
Faces	AdaB	91.51 \pm 0.48	92.17	90.80 \pm 1.37 +	91.87	1.02 \pm 0.12	1.57	0.00 \pm 0.01	0.06
	J48	99.72 \pm 0.11	99.80	96.57 \pm 0.38 =	96.97	0.89 \pm 0.12	1.34	0.01 \pm 0.02	0.12
	k-NN	100.0 \pm 0.00	100.0	96.52 \pm 0.31 =	96.93	6.70 \pm 0.38	7.55	8.56 \pm 0.68	9.88
	NB	91.62 \pm 0.70	92.60	92.19 \pm 0.45 +	92.67	0.45 \pm 0.06	0.66	0.33 \pm 0.02	0.43
	SVM	99.38 \pm 0.18	99.63	97.48 \pm 0.31 =	97.83	0.96 \pm 0.15	1.31	0.01 \pm 0.00	0.02
	ConvNet	99.81 \pm 0.20	99.97	99.29 \pm 0.24 =	99.63	113.22 \pm 11.64	148.91	0.43 \pm 0.07	0.69
	2TGP	96.26 \pm 2.35	98.80	96.04 \pm 2.38 =	98.60	424.64 \pm 108.20	822.19	0.03 \pm 0.02	0.19
	ConvGP	95.29 \pm 2.81	99.23	94.93 \pm 2.68	98.47	963.11 \pm 598.58	2646.28	0.10 \pm 0.09	0.39
Pedestrian	AdaB	79.26 \pm 1.81	80.96	77.72 \pm 1.57 =	79.21	3.11 \pm 0.50	4.36	0.01 \pm 0.00	0.01
	J48	99.28 \pm 0.08	99.38	89.24 \pm 0.31 =	89.67	4.59 \pm 0.64	5.96	0.01 \pm 0.00	0.01
	k-NN	100.0 \pm 0.00	100.0	98.08 \pm 0.24 =	98.40	27.58 \pm 3.09	37.52	41.44 \pm 4.48	55.91
	NB	77.21 \pm 0.24	77.38	76.53 \pm 0.35 +	77.02	1.14 \pm 0.06	1.44	0.87 \pm 0.01	0.93
	SVM	90.65 \pm 0.12	90.79	84.48 \pm 0.41 =	85.00	84.68 \pm 10.50	99.74	0.03 \pm 0.01	0.05
	ConvNet	99.96 \pm 0.04	100.0	97.60 \pm 0.19 =	98.17	315.77 \pm 10.75	349.88	1.27 \pm 0.11	1.51
	2TGP	82.53 \pm 2.35	86.33	81.95 \pm 2.44 =	85.42	1984.63 \pm 519.34	3545.93	0.16 \pm 0.12	0.59
	ConvGP	81.27 \pm 2.95	86.96	80.59 \pm 2.96	86.00	3285.11 \pm 2179.03	11554.99	0.31 \pm 0.29	1.49

A filter based genetic algorithm and neural network technique for Image Classification

Purushottam Das

Department of Computer Sc. & Engg.
Graphic Era Deemed to be University
Dehradun, India
purushottamdas82@gmail.com

Dinesh C. Dobhal

Department of Computer Sc. & Engg.
Graphic Era Deemed to be University
Dehradun, India
dineshdobhal@gmail.com

Ankur Singh Bist

Department of Computer Sc. & Engg.
Graphic Era Hill University
Bhimtal, India
ankur1990bist@gmail.com

Shambhu Prasad Sah

Department of Computer Sc. & Engg.
Graphic Era Hill University
Bhimtal, India
somusuman@gmail.com

Dikendra K. Verma

Department of ECE
Graphic Era Hill University
Bhimtal, India
dikendraverma@gmail.com

Saurabh Pargaen

Department of ECE
Graphic Era Hill University
Bhimtal, India
saurabhpargaen@gmail.com

No. of features selected	Testing	Validation	Total
2	81.5	81.5	79.2
3	92.6	85.2	91.6
4	70.4	59.3	69.7
5	88.9	92.6	97.2

Data set	No. of Features Selected	Selected Feature Subset	Classification Results		
			Testing	Validation	Total
Wine	5	(11, 13, 7, 3, 5)	88.9	92.6	97.2

Puntos Clave

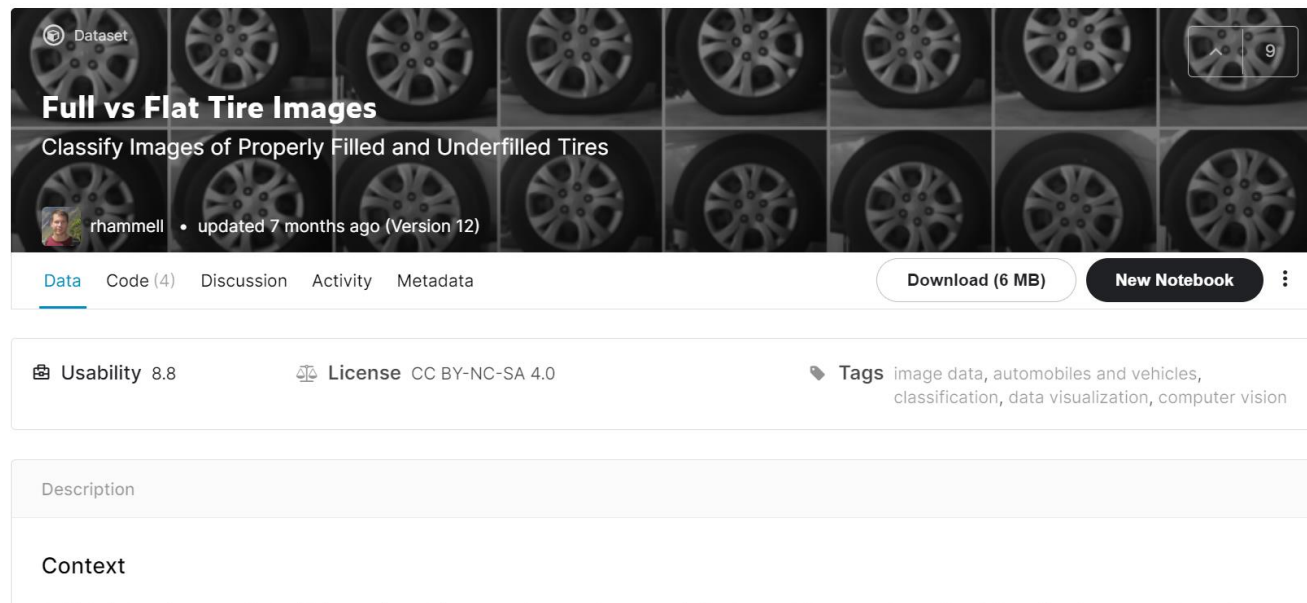
- Clasificación de imágenes.
- Algoritmo genético basado en filtros para optimización de características y en redes neuronales.
- Precisión máxima del 97,2%, superando el rendimiento del 61,2% de un multi-SVM.

Agenda

1. Contextualización
2. Estado del arte
- 3. Metodología**
4. Resultados
5. Conclusiones
6. Repositorio Github



1. Selección de la base de datos.
2. Preprocesamiento de las imágenes.
3. Protocolo experimental.

1. Selección de la base de datos.



- Imágenes de llantas a blanco y negro de 240x240x3.
- (2) categorías, inflado (1) y desinflado (0).
- 300 imágenes por categoría.

1. Selección de la base de datos.
2. Preprocesamiento de las imágenes.
3. Protocolo experimental.



GA

Busqueda de Parametros 1

```
pca_f = [50, 70, 100]
estimators = [log_reg, k_n]
estimators_names = ['Regresion Logistica', 'K_nearest']
population_i = [0.1, 0.2, 0.3, 0.4]
generation_n = [20, 40, 60]
```

N_Caract	70
Estimador	Regresion Logistica
Poblacion inicial	0.3
N_Generaciones	60



Busqueda de Parametros 2

```
max_f = [5, 10, 20]
c_proba = [0.3, 0.5, 0.7]
m_proba = [0.1, 0.2, 0.3]
c_i_proba = [0.1, 0.3, 0.5]
m_i_proba = [0.03, 0.05, 0.07, 0.1]
t_size = [3, 5, 10]
```

Max_features	5.000000
cross_Prob	0.300000
Mutation_Prob	0.200000
Cross_ind_Prob	0.500000
Mutation_Ind_Prob	0.070000
Tournament_Size	5.000000

Agenda

1. Contextualización
2. Estado del arte
3. Metodología
- 4. Resultados**
5. Conclusiones
6. Repositorio Github


Resultados



Pontificia Universidad
JAVERIANA
Bogotá


Busqueda de Parametros 1

	precision	recall	f1-score	support
0.0	0.91	0.81	0.85	98
1.0	0.80	0.90	0.85	82
accuracy			0.85	180
macro avg	0.85	0.85	0.85	180
weighted avg	0.86	0.85	0.85	180



Busqueda de Parametros 2

	precision	recall	f1-score	support
0.0	0.92	0.85	0.88	98
1.0	0.83	0.91	0.87	82
accuracy			0.88	180
macro avg	0.88	0.88	0.88	180
weighted avg	0.88	0.88	0.88	180



Agenda

1. Contextualización
2. Estado del arte
3. Metodología
4. Resultados
- 5. Conclusiones**
6. Repositorio Github

- La reducción de dimensionalidad demuestra ser una herramienta útil en aplicaciones donde se requiere disminuir la complejidad de los datos.
- Se demuestra que es posible solucionar el problema de clasificación de imágenes usando algoritmos genéticos, siempre y cuando se logre una reducción dimensional.

- De la búsqueda inicial, los mejores resultados se obtuvieron usando 70 componentes principales superando aquellos modelos que tenían 100, esto se puede deber a que la información codificada por las pruebas con 100 componentes corresponde a variables que poco aportan a la clasificación del estado de las llantas, por ejemplo, tipo y color de rines.
- En la segunda búsqueda, se logra un mejor resultado aumentando el tamaño del torneo y de las probabilidades independientes mutación.

Agenda

1. Contextualización
2. Estado del arte
3. Metodología
4. Resultados
5. Conclusiones
- 6. Repositorio Github**

URL Respositorio de Proyecto Clasificación de llantas a partir de imágenes:

<https://github.com/katherinegonzalez/ClasificacionLlantas>

- [1] «Agencia Nacional de Seguridad Vial. ANSV». [En línea]. Disponible en: www.ansv.gov.co
- [2] «Fallas en las llantas, la segunda causa más frecuente de accidentes de tránsito en el país», *Revista Semana*, mar. 2022, [En línea]. Disponible en: <https://www.semana.com/finanzas/consumo-inteligente/articulo/fallas-en-las-llantas-la-segunda-causa-mas-frecuente-de-accidentes-de-transito-en-el-pais/202243/>
- [3] «Fallas y desgaste en las llantas entre las causas que más provocan siniestros viales en Colombia». <https://www.mintransporte.gov.co/publicaciones/10748/fallas-y-desgaste-en-las-llantas-entre-las-causas-que-mas-provocan-siniestros-viales-en-colombia/> (accedido 18 de abril de 2022).
- [4] «Accident Prevention by Monitoring and Control of Vehicle Tyre Pressure using Wear & Tear and Pressure Sensor», *Int. J. Recent Technol. Eng.*, vol. 8, n.º 2, pp. 5281-5284, jul. 2019, doi: 10.35940/ijrte.B1061.078219.
- [5] O. A. Egaji, S. Chakhar, y D. Brown, «An innovative decision rule approach to tyre pressure monitoring», *Expert Syst. Appl.*, vol. 124, pp. 252-270, jun. 2019, doi: 10.1016/j.eswa.2019.01.051.
- [6] K.-Y. Chen y C.-F. Yeh, «Preventing Tire Blowout Accidents: A Perspective on Factors Affecting Drivers' Intention to Adopt Tire Pressure Monitoring System», *Safety*, vol. 4, n.º 2, p. 16, abr. 2018, doi: 10.3390/safety4020016.
- [7] N. T. Ratrou, «Tire condition and drivers' practice in maintaining tires in Saudi Arabia», *Accid. Anal. Prev.*, vol. 37, n.º 1, pp. 201-206, ene. 2005, doi: 10.1016/j.aap.2003.03.001.

- [8] Ministerio de transporte, «Resolución 0001349 de 2017 CALE».
- [9] Ministerio de transporte, «Resolución 001600 de 2005 - REPUBLICA DE COLOMBIA», 2005.
- [10] «USTMA Announces Tire Safety Week 2022: June 27-July 3.», *Waste360*, p. N.PAG-N.PAG, feb. 2022.
- [11] «Full vs Flat Tire Images». <https://kaggle.com/datasets/rhammell/full-vs-flat-tire-images> (accedido 21 de marzo de 2022).
- [12] «Peajes en Colombia: ¿desde cuándo es el cobro y en cuáles aplica?», 31 de mayo de 2020. https://colombia.as.com/colombia/2020/06/01/actualidad/1590977340_706151.html (accedido 18 de abril de 2022).
- [13] «Las empresas de transporte cobran protagonismo en la actualidad – Bu Ytrago». <https://buytrago.es/las-empresas-de-transporte-cobran-protagonismo-en-la-actualidad/> (accedido 18 de abril de 2022).
- [14] «Vector Icons and Stickers - PNG, SVG, EPS, PSD and CSS». <https://www.flaticon.com/> (accedido 18 de abril de 2022).
- [15] [2] M. Chen y Z. Yao, «Classification Techniques of Neural Networks Using Improved Genetic Algorithms», en 2008 Second International Conference on Genetic and Evolutionary Computing, sep. 2008, pp. 115-119. doi: 10.1109/WGEC.2008.23.
- [16] Z. Qiao, Q. Zhang, Y. Dong, y J.-J. Yang, «Application of SVM based on genet-ic algorithm in classification of cataract fundus images», en 2017 IEEE Interna-tional Conference on Imaging Systems and Techniques (IST), oct. 2017, pp. 1-5. doi: 10.1109/IST.2017.8261541.

- [17] B. Evans, H. Al-Sahaf, B. Xue, y M. Zhang, «Evolutionary Deep Learning: A Genetic Programming Approach to Image Classification», en 2018 IEEE Congress on Evolutionary Computation (CEC), jul. 2018, pp. 1-6. doi: 10.1109/CEC.2018.8477933.
- [18] P. Das, D. C. Dobhal, A. S. Bist, S. P. Sah, D. K. Verma, y S. Pargaien, «A filter based genetic algorithm and neural network technique for Image Classification», en 2020 IEEE International Conference on Advent Trends in Multidisciplinary Research and Innovation (ICATMRI), dic. 2020, pp. 1-4. doi: 10.1109/ICATMRI51801.2020.9398498.



Pontificia Universidad
JAVERIANA
Bogotá

Gracias