



Pontificia Universidad
JAVERIANA
Bogotá

Clasificación de estado de presión de llantas de vehículos a partir de imágenes

Juan Nicolás Soto Rios
Frank M. Córdoba O.
Katherine Xiomar González Santacruz

Agenda

1. Contextualización
2. Estado del arte
3. Metodología
4. Resultados
5. Conclusiones
6. Repositorio Github

- 1. Contextualización**
2. Estado del arte
3. Metodología
4. Resultados
5. Conclusiones
6. Repositorio Github

- De acuerdo a la ANSV en Colombia las fallas de las llantas son la segunda causa que más provoca accidentes viales [1].
- Según el Registro único Nacional de Tránsito, en 2021 se registraron más de **1970** accidentes asociados a fallas en las llantas, en los cuales **640** personas resultaron heridas, **64** fallecieron y **1271** sufrieron daños materiales [2].

- El Ministerio de transporte sugiere que es importante realizar una revisión continua del estado de inflado de las llantas de los vehículos, para mejorar la seguridad a la hora de conducir, la economía del combustible y la vida útil de las llantas [2].

- Si las llantas se encuentran un 20% desinfladas [3]:
 - Se disminuye su vida útil en un 30%
 - Aumenta el consumo de combustible en un 3%
 - Riesgo de accidentes
- Normalmente no se presta atención a la condición de las llantas [3][4].

Se implementa un mecanismo de clasificación utilizando redes neuronales para determinar el estado – inflado o desinflado – de una llanta, a partir de imágenes, con el fin de aumentar la seguridad de la conducción, reducir el consumo de combustible, y mejorar la vida útil de las llantas.



Fuente [5]

Agenda

1. Contextualización
- 2. Estado del arte**
3. Metodología
4. Resultados
5. Conclusiones
6. Repositorio Github

Indirect Tire Monitoring System - Machine Learning Approach

O Svensson¹, S Thelin², S Byttner and Y Fan

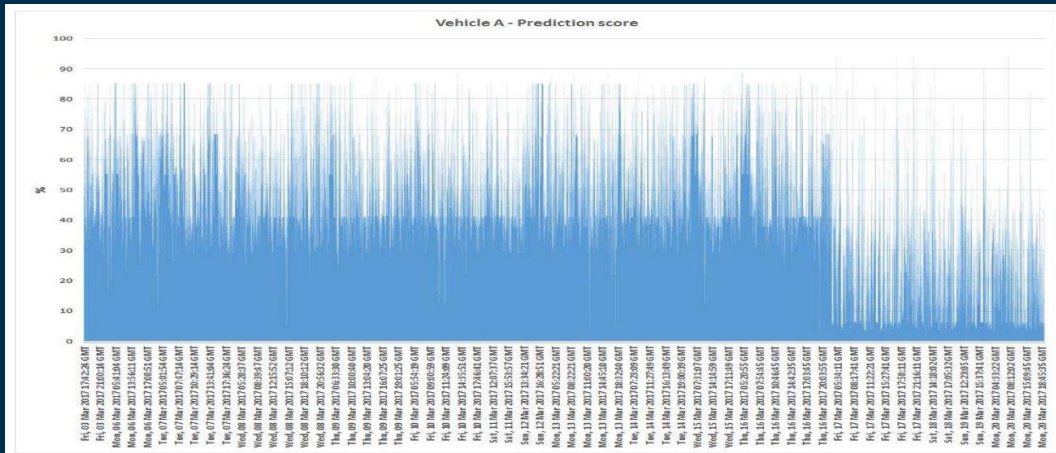
Department of Intelligent Systems and Digital Design, Halmstad University, Box 823, S301 18
Halmstad, Sweden

E-mail: ¹oskarsvensson.94@gmail.com, ²simon.thelin90@gmail.com

{[stefan.byttner](mailto:stefan.byttner@hh.se), [yuantao.fan](mailto:yuantao.fan@hh.se)}@hh.se

Puntos Clave

- Clasificación de buen o mal estado de un vehículo.
- Datos obtenidos de los mismos vehículos a clasificar.
- Random Forest con validación cruzada en Python.
- Precisión del 90,54%.



Applying Neural Networks for Tire Pressure Monitoring Systems

Alex Kost, *California Polytechnic State University, San Luis Obispo*

DOI: <https://doi.org/10.15368/theses.2018.5>

Available at: <https://digitalcommons.calpoly.edu/theses/1827>

Table 4.1: Final hyperparameters chosen for both models.

Name	RNN-LSTM	CNN
dropout_rate	0.672	0.309
learning_rate	0.00001	0.033
beta1	0.9	0.684
beta2	0.999	0.845
epsilon	1e-08	0.282
num_filt_1	-	16
kernel_size	-	4
num_fc_1	31	6
n_layers	4	-
n_hidden	22	-




Figure 4.2: Classification Accuracy During Training

Puntos Clave

- TPMS indirecto para clasificar entre presión baja, normal y alta.
- Redes neuronales recurrentes (RNN-LSTM) y una red neuronal convolucional (CNN) desarrollada en Python.
- Optimización bayesiana y grid search para optimizar el entrenamiento y los parámetros del modelo.
- Los modelos CNN y RNN lograron una precisión superior al 90% en el conjunto de datos de validación y prueba.

Automotive Diagnostics as a Service: An Artificially Intelligent Mobile Application for Tire Condition Assessment

June 2018

DOI:[10.1007/978-3-319-94361-9_13](https://doi.org/10.1007/978-3-319-94361-9_13)

In book: Artificial Intelligence and Mobile Services – AIMS 2018 (pp.172-184)

Project: [Cell phone data based vehicle diagnostics](#)

Authors:

Josh Siegel

Michigan State University

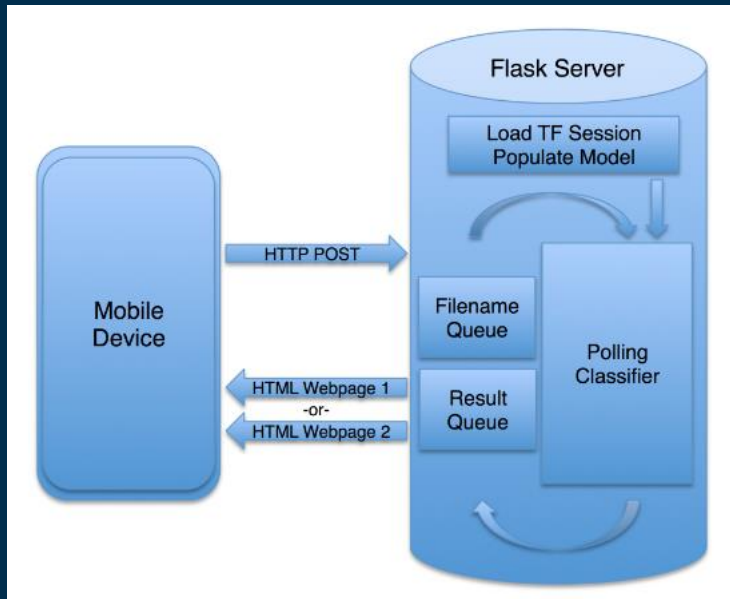
Yongbin Sun

mit

Sanjay E. Sarma

Massachusetts Institute of Technology

	Actual Cracked	Actual Good
Predicted Cracked	164	46
Predicted Good	24	91



Puntos Clave

- Clasificación entre neumáticos agrietados y en buen estado a partir de imágenes de teléfonos.
- Red neuronal convolucional (CNN), VGG-16 y DenseNets desarrolladas en Python.
- Imágenes recortadas a 224x224px de ruedas de motores de búsqueda con diversas condiciones.
- Precisión del 78,5% en imágenes de muestra recortadas, superando el rendimiento del 55% de los humanos inexpertos.

© 2020

Smart Computing Paradigms: New Progresses and Challenges

Proceedings of ICACNI 2018, Volume 1

Atilla Elçi, Pankaj Kumar Sa, Chirag N. Modi, Gustavo Olague, Manmath N. Sahoo, Sambit Bakshi

Puntos Clave

Table 2 Comparing results between different classifiers and number of folds

Folds (k)	Random forest	AdaBoost	Neural networks
2	62.22	58.88	63.33
3	58.88	56.66	67.77
4	53.31	58.84	65.41
5	52.22	56.66	67.77
6	53.33	55.55	65.55
7	52.19	53.29	61.17
8	58.90	56.43	64.10
9	53.33	54.44	64.44
10	58.88	54.44	65.55
11	53.03	55.42	65.15
12	50.14	55.05	65.92
13	44.13	50.01	59.34
14	49.31	51.36	58.84
15	43.33	45.55	58.88

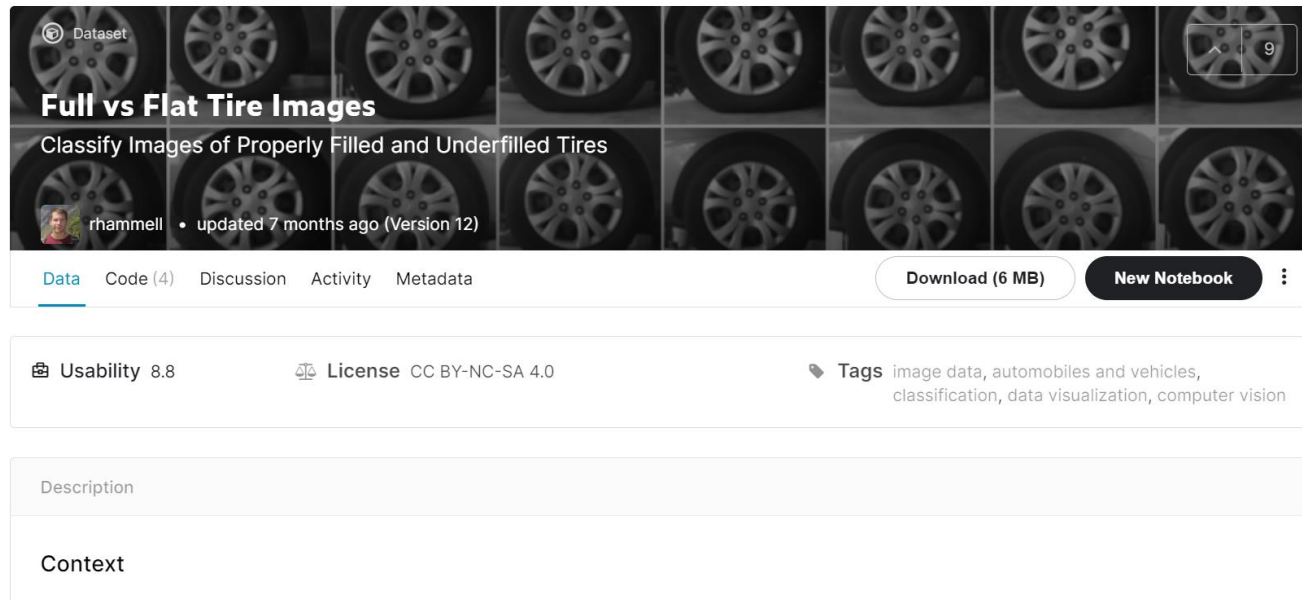
- Clasificación entre presión normal y baja de neumáticos a partir de imágenes de la rueda.
- Random Forest, AdaBoost y Redes Neuronales con 4 neuronas en la capa de entrada, 2 capas ocultas con 10 y 4 neuronas y una neurona en la capa de salida con una función de activación ReLU.
- Imágenes recortadas a 640x480px de ruedas de automóviles.
- Las redes neuronales obtuvieron consistentemente mejores resultados (de alrededor del 68%) que los otros dos clasificadores.

Agenda

1. Contextualización
2. Estado del arte
- 3. Metodología**
4. Resultados
5. Conclusiones
6. Repositorio Github



1. Selección de la base de datos.
2. Preprocesamiento de las imágenes.
3. Entrenamiento de los modelos.
4. Protocolo experimental.

1. Selección de la base de datos.
2. Preprocesamiento de las imágenes.



- Imágenes de llantas a blanco y negro de 240x240x3.
- (2) categorías, inflado (1) y desinflado (0).
- 300 imágenes por categoría.


1. Selección de la base de datos.
2. Preprocesamiento de las imágenes.
3. Entrenamiento de los modelos.
4. Protocolo experimental.




Reducción a un canal



RN

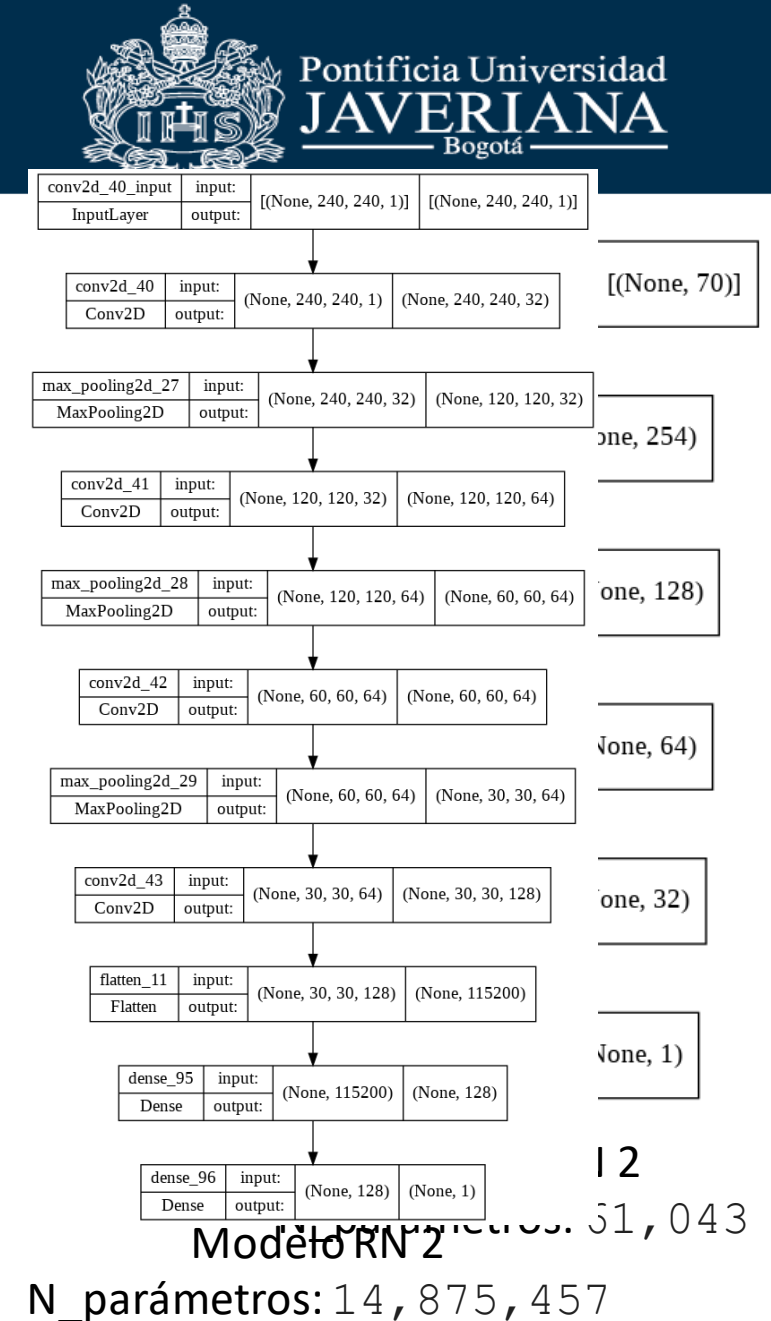
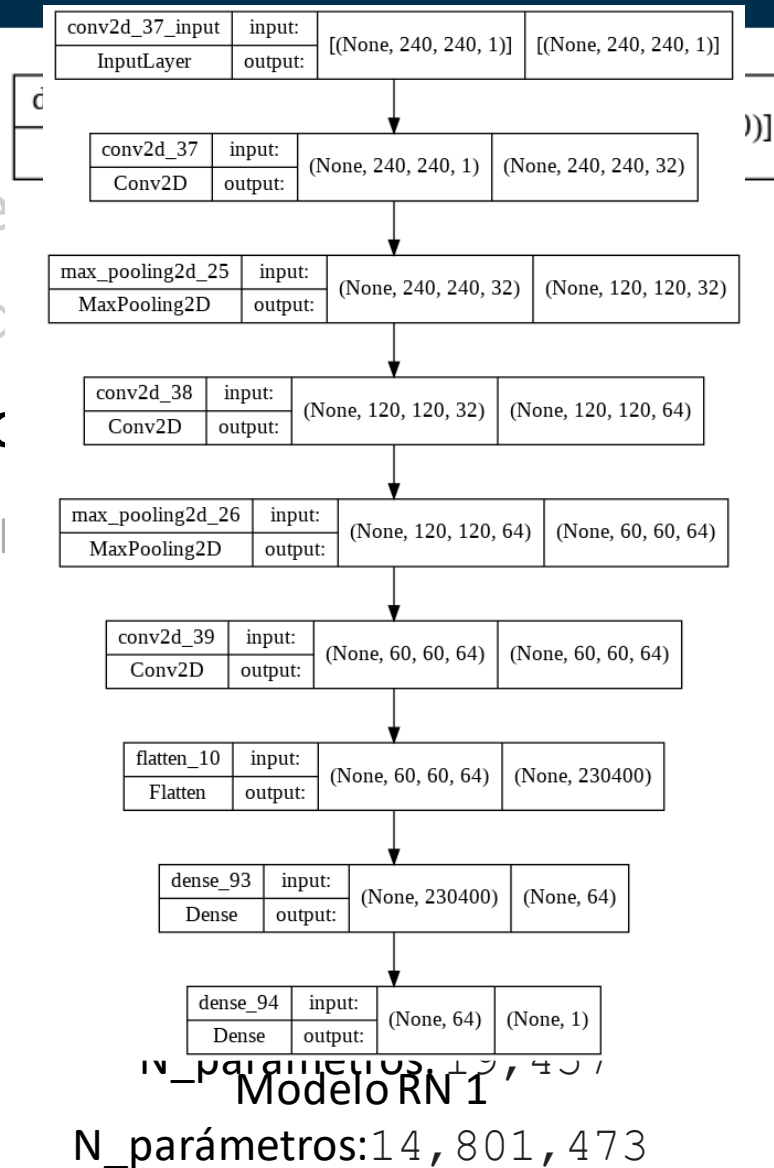


CNN




Metodología

1. Selección de la base
2. Preprocesamiento c
3. Entrenamiento de l
4. Protocolo experime



1. Selección de la base de datos.
2. Preprocesamiento de las imágenes.
3. Entrenamiento de los modelos.
4. Protocolo experimental.



	precision	recall	f1-score	support
0.0	1.00	1.00	1.00	31
1.0	1.00	1.00	1.00	23
accuracy			1.00	54
macro avg	1.00	1.00	1.00	54
weighted avg	1.00	1.00	1.00	54

Agenda

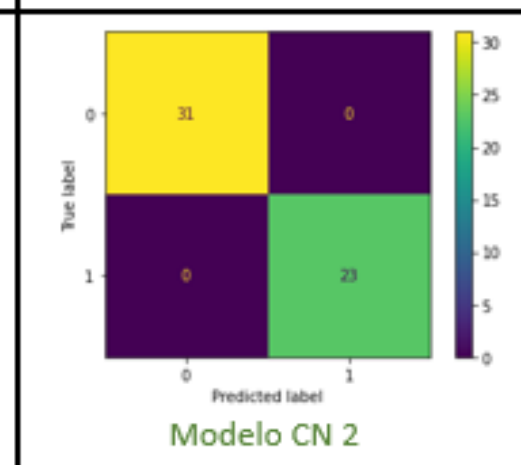
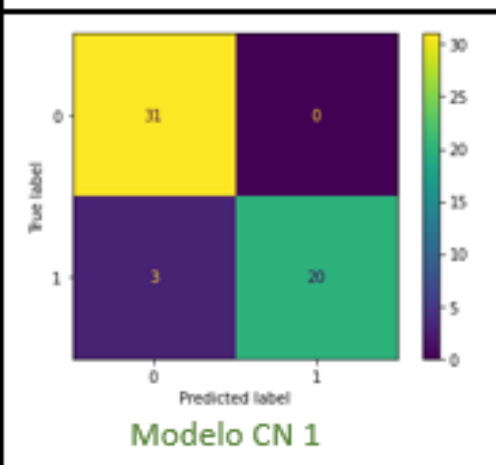

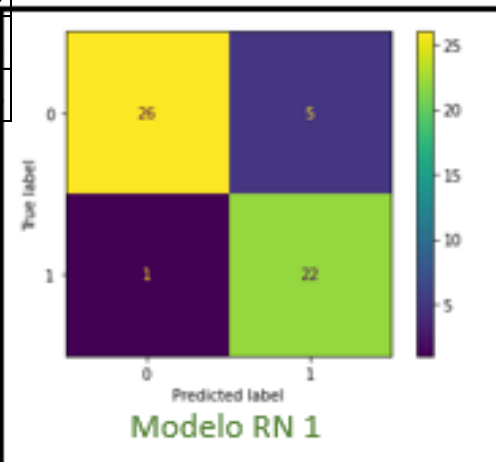
1. Contextualización
2. Estado del arte
3. Metodología
- 4. Resultados**
5. Conclusiones
6. Repositorio Github

Resultados



Pontificia Universidad
JAVERIANA
Bogotá

	Precision Cat 0	Precision Cat 1	Accuracy	Tiempo entrenamiento (min)
Modelo RN 1	0,96	0,81	0,89	0,03
Modelo RN 2	0,97	0,96	0,96	0,05
Modelo CN 1	0,91	1,0	0,94	6,03
Modelo CN 2	1,0	1,0	1,0	6,66



Agenda

1. Contextualización
2. Estado del arte
3. Metodología
4. Resultados
- 5. Conclusiones**
6. Repositorio Github

- La reducción de dimensionalidad demuestra ser una herramienta útil en aplicaciones donde se requiere disminuir la complejidad de los datos.
- Las redes neuronales convencionales demuestran una alta capacidad de clasificación de imágenes a un costo computacional hasta 130 veces menor que las redes convolucionales.

- En ambos enfoques se demuestra que el aumento de capas y neuronas mejora la captura de características de los datos de entrada, aunque, se debe ser cuidadoso de no sobreentrenar el modelo.
- Las redes neuronales convolucionales demuestran ser muy eficientes para la clasificación de imágenes, aunque a un costo computacional superior.
- El aumento de capas de las redes convolucionales aumenta su capacidad de encontrar características que favorezcan la clasificación.

Agenda

1. Contextualización
2. Estado del arte
3. Metodología
4. Resultados
5. Conclusiones
- 6. Repositorio Github**

URL Respositorio de Proyecto Clasificación de llantas a partir de imágenes:

<https://github.com/katherinegonzalez/ClasificacionLlantas>

- [1] «Agencia Nacional de Seguridad Vial. ANSV». [En línea]. Disponible en: www.ansv.gov.co
- [2] «Fallas en las llantas, la segunda causa más frecuente de accidentes de tránsito en el país», *Revista Semana*, mar. 2022, [En línea]. Disponible en: <https://www.semana.com/finanzas/consumo-inteligente/articulo/fallas-en-las-llantas-la-segunda-causa-mas-frecuente-de-accidentes-de-transito-en-el-pais/202243/>
- [3] «Accident Prevention by Monitoring and Control of Vehicle Tyre Pressure using Wear & Tear and Pressure Sensor», *Int. J. Recent Technol. Eng.*, vol. 8, n.º 2, pp. 5281-5284, jul. 2019, doi: 10.35940/ijrte.B1061.078219.
- [4] O. A. Egaji, S. Chakhar, y D. Brown, «An innovative decision rule approach to tyre pressure monitoring», *Expert Syst. Appl.*, vol. 124, pp. 252-270, jun. 2019, doi: 10.1016/j.eswa.2019.01.051.
- [5] «Full vs Flat Tire Images». <https://kaggle.com/datasets/rhammell/full-vs-flat-tire-images> (accedido 21 de marzo de 2022).
- [6] O. Svensson, S. Thelin, S. Byttner, y Y. Fan, «Indirect Tire Monitoring System - Machine Learning Approach», *IOP Conf. Ser. Mater. Sci. Eng.*, vol. 252, p. 012018, oct. 2017, doi: 10.1088/1757-899X/252/1/012018.

- [7] A. Kost, «Applying Neural Networks for Tire Pressure Monitoring Systems», *Masters Theses*, mar. 2018, doi: 10.15368/theses.2018.5.
- [8] J. E. Siegel, Y. Sun, y S. Sarma, «Automotive Diagnostics as a Service: An Artificially Intelligent Mobile Application for Tire Condition Assessment», en *Artificial Intelligence and Mobile Services – AIMS 2018*, Cham, 2018, pp. 172-184. doi: 10.1007/978-3-319-94361-9_13.
- [9] A. Elçi, P. K. Sa, C. N. Modi, G. Olague, M. N. Sahoo, y S. Bakshi, *Smart Computing Paradigms: New Progresses and Challenges: Proceedings of ICACNI 2018, Volume 1*. Springer Nature, 2019.



Pontificia Universidad
JAVERIANA
Bogotá

Gracias